

RAPPORT DU PARCOURS CONFIRME PYTHON

QUESTIONS DE COURS ET RESULTATS DES SCRIPTS

SEANCE 05

REPONSES AUX QUESTIONS

1. Comment définir l'échantillonnage. Pourquoi ne pas utiliser la population en entier ? Quelles sont les méthodes d'échantillonnage ? Comment les choisir ?

L'échantillonnage est une méthode qui consiste à sélectionner une partie d'une population afin d'en tirer des conclusions générales. On étudie un groupe réduit d'individus de la population mère, pour comprendre ou estimer les caractéristiques de l'ensemble de la population. Cela permet d'éviter à avoir d'étudier l'ensemble de la population. L'objectif est que cet échantillon soit représentatif, c'est-à-dire qu'il reflète fidèlement la diversité, les proportions et la structure de la population globale.

On n'utilise pas la population entière pour plusieurs raisons. D'abord pour une raison de coût, recueillir des données sur chaque individu d'une population peut être extrêmement cher, surtout si celle-ci est très grande. Ensuite pour une raison de temps, analyser des millions de cas prendrait beaucoup trop longtemps, alors qu'un échantillon permet d'obtenir des résultats rapides et fiables. Enfin, il y a aussi des questions de faisabilité. En effet, certaines populations sont difficiles à atteindre ou à recenser entièrement.

Il existe plusieurs méthodes d'échantillonnage, les méthodes aléatoires et les méthodes non aléatoires.

Les méthodes aléatoires reposent sur le hasard. Chacun a la même probabilité d'être sélectionné :

- L'échantillonnage aléatoire simple, où l'on prend des individus au hasard dans la population,
- L'échantillonnage stratifié, où la population est divisée en groupes homogènes avant de tirer au hasard dans chaque groupe,
- L'échantillonnage par grappes, où ce sont des groupes entiers spécifiques (écoles, quartiers, foyers, ...) qui sont tirés au hasard.

Les méthodes non aléatoires reposent sur un choix raisonné ou pratique. Le choix de la méthode d'échantillonnage dépend de plusieurs facteurs. Il faut d'abord considérer l'objectif de l'étude, une enquête scientifique exige souvent un échantillonnage aléatoire, tandis qu'une étude rapide

correspond mieux à une méthode non aléatoire. Le budget, le temps disponible, la taille de la population et l'accessibilité des individus jouent aussi un rôle important.

2. Comment définir un estimateur et une estimation ?

Un estimateur est un moyen statistique qui permet d'estimer une caractéristique inconnue d'une population, comme sa moyenne, sa proportion ou sa variance. Il s'agit donc d'un outil théorique qui indique comment calculer cette information à partir d'un échantillon.

L'estimation, quant à elle, est la valeur numérique obtenue lorsque l'on applique cet estimateur à un échantillon précis. L'estimation est donc le résultat concret donné par l'estimateur.

3. Comment distingueriez-vous l'intervalle de fluctuation et l'intervalle de confiance ?

L'intervalle de fluctuation permet d'évaluer la variabilité d'une statistique d'échantillon autour de sa valeur attendue lorsque l'on répète l'expérience ou le prélèvement d'échantillons. Si l'on prélève plusieurs échantillons d'une même taille dans une population donnée, la proportion observée dans chaque échantillon peut varier. L'intervalle de fluctuation indique donc la plage de valeurs dans laquelle cette proportion devrait se situer dans la majorité des échantillons, avec un niveau de confiance de 95 %. Il sert principalement à contrôler si un résultat observé est cohérent avec une hypothèse connue sur la population.

L'intervalle de confiance est utilisé pour estimer une caractéristique inconnue de la population, comme une moyenne ou une proportion, à partir d'un seul échantillon. Il fournit une plage de valeurs pour le paramètre inconnu avec un certain niveau de confiance. L'intervalle de confiance contient le paramètre réel de la population avec une probabilité donnée, et il est construit à partir des données observées dans un échantillon unique.

4. Qu'est-ce qu'un biais dans la théorie de l'estimation ?

Dans la théorie de l'estimation, un biais désigne la différence entre la valeur moyenne d'un estimateur et la vraie valeur du paramètre de la population qu'il cherche à estimer. Autrement dit, un estimateur est dit biaisé si, en moyenne, il surestime ou sous-estime systématiquement le paramètre réel. À l'inverse, un estimateur est non biaisé si sa valeur moyenne, lorsqu'on répète l'expérience ou le prélèvement de nombreux échantillons, coïncide exactement avec le paramètre réel.

5. Comment appelle-t-on une statistique travaillant sur la population totale ? Faites le lien avec la notion de données massives 1 ?

Une statistique qui travaille sur la population totale s'appelle une statistique descriptive de population. Ces statistiques sont calculées sur l'ensemble des individus de la population.

Elles donnent donc la valeur exacte du paramètre étudié, sans incertitude liée à l'échantillonnage.

Le lien avec les données massives est direct. Les technologies de collecte et de traitement de grandes quantités de données permettent aujourd'hui de travailler sur des populations très vastes, voire sur la quasi-totalité de la population concernée, plutôt que sur un simple échantillon. Dans ce contexte, certaines statistiques calculées sur les données massives peuvent être considérées comme des paramètres exacts, car elles utilisent l'ensemble des données disponibles. Cela réduit l'incertitude et les erreurs liées à l'échantillonnage et permet des analyses plus précises et détaillées.

6. Quels sont les enjeux autour du choix d'un estimateur ?

Le choix d'un estimateur est crucial en statistique, car il détermine la fiabilité et la précision des conclusions que l'on pourra tirer à partir des données. Il y a donc plusieurs enjeux.

Le premier enjeu est celui du biais. Un bon estimateur doit être non biaisé, c'est-à-dire qu'en moyenne, il doit fournir la valeur réelle du paramètre de la population. Si l'estimateur est biaisé, il risque de surestimer ou sous-estimer systématiquement le paramètre, ce qui peut conduire à des conclusions erronées.

Le second enjeu est celui de la variance ou de la dispersion de l'estimateur. Un estimateur non biaisé peut donner des résultats très différents selon l'échantillon choisi. Un bon estimateur doit donc être stable et peu variable, afin que les résultats restent proches de la valeur réelle quelles que soient les observations tirées.

Le troisième enjeu concerne la consistance de l'estimateur. Lorsqu'on augmente la taille de l'échantillon, un estimateur consistant doit se rapprocher de la vraie valeur du paramètre. Cela garantit que les conclusions deviennent plus fiables lorsque l'on dispose de davantage de données.

7. Quelles sont les méthodes d'estimation d'un paramètre ? Comment en sélectionner une ?

En statistique, estimer un paramètre de population consiste à utiliser un estimateur pour obtenir une valeur approximative de ce paramètre à partir d'un échantillon. Il existe plusieurs méthodes d'estimation, chacune ayant ses avantages et ses limites.

La première méthode est l'estimation par la méthode des moments. Elle consiste à évaluer les moments théoriques du paramètre (comme la moyenne ou la variance) aux moments observés dans l'échantillon.

La deuxième méthode est l'estimation par la méthode du maximum de vraisemblance. Cette approche cherche le paramètre qui rend les données observées les plus probables. Elle produit souvent des estimateurs efficaces et consiste à exploiter pleinement l'information contenue dans l'échantillon.

Une troisième approche est l'estimation bayésienne, qui combine les données observées avec des informations sur le paramètre. Cette méthode permet de mettre à jour les connaissances sur

le paramètre en intégrant les observations et les hypothèses initiales, ce qui est utile lorsque l'on dispose de données limitées ou que l'on souhaite incorporer des connaissances antérieures.

Le choix de la méthode d'estimation dépend de plusieurs critères. Il faut prendre en compte la nature des données et la distribution du paramètre, la simplicité de calcul, la qualité souhaitée de l'estimation (biais, variance, consistance), ainsi que la disponibilité d'informations supplémentaires.

8. Quels sont les tests statistiques existants ? À quoi servent-ils ? Comment créer un test ?

Il existe une grande variété de tests statistiques, chacun adapté à une situation particulière et au type de données étudiées. Parmi les plus connus, on retrouve les tests sur les moyennes, comme le test t de Student qui compare la moyenne d'un échantillon à une valeur théorique ou à celle d'un autre échantillon. D'autres tests portent sur les proportions, tels que le test du χ^2 d'indépendance qui examine la relation entre deux variables catégorielles, ou le test de proportion qui confronte une proportion observée à une proportion théorique. Les tests de corrélation et d'association, comme le coefficient de Spearman, de Kendall ou le test de Pearson, servent à mesurer la force et la nature des relations entre variables. Enfin, il existe des tests non paramétriques, tels que le test de Wilcoxon, le test de Mann-Whitney ou le test du signe, qui ne supposent pas que les données suivent une loi normale, ainsi que des tests d'ajustement, comme le χ^2 d'ajustement, qui vérifient si une distribution observée correspond à une loi théorique.

Les tests statistiques ont pour finalité de fournir une base objective à la prise de décision. Ils permettent de vérifier des hypothèses concernant des paramètres de population, de détecter des différences entre groupes ou conditions expérimentales, d'évaluer l'indépendance ou la relation entre variables, et de confirmer ou d'infirmer des modèles théoriques. En d'autres termes, ils servent à distinguer les variations dues au hasard de celles qui traduisent des effets réels, garantissant ainsi que les conclusions tirées reposent sur des données fiables plutôt que sur une simple intuition.

La construction d'un test statistique suit une démarche méthodique. Elle commence par la formulation des hypothèses qui est l'hypothèse nulle, qui représente l'absence d'effet ou de différence, et l'hypothèse alternative, qui traduit l'effet ou la différence recherchée. Ensuite, il faut choisir le test approprié en fonction du type de données, de leur distribution et du nombre d'échantillons. Le chercheur définit ensuite le niveau de signification, souvent fixé à 5 %, qui correspond au risque accepté de rejeter l'hypothèse nulle alors qu'elle est vraie. Vient ensuite le calcul de la statistique de test, obtenu grâce à la formule spécifique au test choisi, puis la comparaison de cette statistique à une distribution théorique. Enfin, la décision est prise : si la statistique observée est trop improbable sous l'hypothèse nulle, celle-ci est rejetée, sinon elle est conservée.

9. Que pensez-vous des critiques de la statistique inférentielle ?

Je pense que les critiques de la statistique inférentielle sont justifiées dans certains cas, mais elles ne remettent pas en cause sa valeur fondamentale. L'inférence repose sur des échantillons et des hypothèses, ce qui introduit un risque d'erreur et une incertitude. Mais c'est pour cela que les méthodes statistiques incluent des outils pour quantifier cette incertitude, comme les intervalles de confiance et les tests de significativité. Ces outils permettent de prendre des décisions en connaissant le niveau de risque, ce qui est beaucoup plus fiable que de se baser uniquement sur l'intuition. De même, la critique sur les échantillons biaisés est pertinente, un mauvais échantillon peut fausser les résultats. Avec un échantillonnage et des méthodes adaptées, ce risque peut être fortement réduit. Quant à la dépendance aux modèles et aux hypothèses, cela reflète la puissance de la statistique inférentielle, pour tirer des conclusions sur des populations à partir d'échantillons, il faut poser des hypothèses. L'important est de vérifier leur validité et, si nécessaire, d'utiliser des méthodes non paramétriques ou robustes. Enfin, la mauvaise interprétation des résultats est un problème surtout lié à l'utilisation et la compréhension des outils et non pas à leur conception.

REPONSE QUESTION PYTHON

Expliquer le lien entre l'intervalle de fluctuation et les valeurs réelles de la population mère. Que pouvez-vous en conclure par rapport aux échantillons utilisés pour le calcul ?

Les intervalles de fluctuation permettent de vérifier si les fréquences observées dans l'échantillon sont compatibles avec les valeurs réelles de la population mère. Dans notre cas, les proportions observées pour « pour », « contre » et « sans opinion » se situent toutes à l'intérieur des intervalles calculés : par exemple, la fréquence « sans opinion » de 0,19 appartient bien à l'intervalle (0,1685 ; 0,2175). Cela signifie que les écarts entre l'échantillon et la population peuvent s'expliquer par les fluctuations d'échantillonnage et ne remettent pas en cause les proportions réelles de la population mère. On peut donc conclure que les échantillons utilisés sont cohérents, représentatifs et qu'ils ne montrent aucune contradiction statistique avec les valeurs de la population.

Théorie de l'estimation, dans votre rapport, vous interprétez le résultat obtenu et vous le comparez avec le résultat précédent.

Les nouveaux intervalles de confiance obtenus pour l'échantillon de taille 1000 confirment pleinement les résultats précédents. Les fréquences observées, 0,395 pour « pour », 0,396 pour « contre » et 0,209 pour « sans opinion », se situent toutes à l'intérieur des intervalles calculés, ce qui montre que ces proportions sont compatibles avec les valeurs réelles de la population mère. Par rapport aux intervalles de fluctuation obtenus auparavant, les intervalles de confiance sont légèrement plus larges mais restent centrés autour des mêmes valeurs, ce qui traduit une cohérence statistique entre les deux approches. Le fait que les proportions de l'échantillon coïncident presque exactement avec celles de la population mère confirme que l'échantillon est représentatif et que les écarts observés relèvent uniquement des fluctuations d'échantillonnage. On peut donc conclure que les deux méthodes, intervalle de fluctuation et intervalle de confiance, conduisent à la même interprétation : les échantillons utilisés sont fiables et ne remettent pas en cause les proportions réelles de la population.

Théorie de la décision, vous expliquerez dans votre rapport pourquoi

D'après les résultats du test de Shapiro-Wilk, aucune des deux distributions testées ne peut être considérée comme normale. Dans les deux cas, la p-value est extrêmement faible (proche de zéro), ce qui signifie que la probabilité d'obtenir de tels écarts par rapport à une distribution normale est quasiment nulle. Le test rejette donc clairement l'hypothèse de normalité pour les deux jeux de données. La première distribution présente déjà une statistique de Shapiro-Wilk éloignée de 1, mais la seconde s'en écarte encore davantage, ce qui indique une forme très différente d'une loi normale. On peut ainsi conclure que ni « Loi-normale-Test-1 » ni « Loi-normale-Test-2 » ne suivent une distribution normale, ce qui justifie l'utilisation de méthodes statistiques ne reposant pas sur l'hypothèse de normalité.

RESULTATS SCRIPT

	RESULTAT
Fréquence pour l'opinion de l'échantillon :	- Pour : 0.39 - Contre : 0.42 - Sans opinion : 0.19
Fréquence pour l'opinion de la population mère	- Pour : 0.39 - Contre : 0.42 - Sans opinion : 0.19
	(0.3607550342965974, 0.42124496570340264)
	(0.3854501445109801, 0.4465498554890199)
	(0.16853915288466076, 0.21746084711533925)
Résultat sur le calcul d'un intervalle de fluctuation :	(0.16853915288466076, 0.21746084711533925)
Premier échantillon converti en liste :	[395, 396, 209]
Fréquences	[0.395, 0.396, 0.209]
Intervalle de confiance : Pour	Fréquence = 0.395, IC95 = (0.36470072014057103, 0.425299279859429)
Intervalle de confiance : Contre	Fréquence = 0.396, IC95 = (0.36568747363877435, 0.4263125263612257)
Intervalle de confiance : Sans opinion	Fréquence = 0.209, IC95 = (0.18379901846355978, 0.2342009815364402)
Test Shapiro-Wilk pour Loi-normale-Test-1	Statistique = 0.9639365077018738 p-value = 6.236865583131948e-22

	La distribution est Non normale
Test Shapiro-Wilk pour Loi-normale-Test-2	Statistique = 0.26088815927505493 p-value = 0.0 La distribution est Non normale

SEANCE 06

REPONSES AUX QUESTIONS

- 1. Qu'est-ce qu'une statistique ordinale ? À quelle autre statistique catégorielle s'oppose-t-elle ? Quel type de variables utilise-t-elle ? En quoi cela peut matérialiser une hiérarchie spatiale ?**

Une statistique ordinale est un type de statistique qui utilise des catégories classées dans un certain ordre. Cela signifie qu'on peut dire qu'une catégorie est « plus » ou « moins » qu'une autre, mais sans pouvoir mesurer exactement la différence entre elles. Par exemple, si l'on classe des personnes comme « peu satisfaites », « moyennement satisfaites » et « très satisfaites »

», on connaît l'ordre des niveaux, mais on ne sait pas de combien « très satisfait » est au-dessus de « moyennement satisfait ».

Ce type de statistique s'oppose à la statistique nominale, qui utilise aussi des catégories mais sans ordre, comme les couleurs, les nationalités ou les types de voitures. Dans une statistique nominale, une catégorie n'est jamais « au-dessus » ou « dessous » d'une autre, elles sont simplement différentes. Contrairement aux statistiques ordinales qui reposent sur l'idée d'un classement.

Les statistiques ordinales utilisent des variables qualitatives ordinales, c'est-à-dire des variables constituées de catégories rangées de la plus faible à la plus élevée. Ces variables ne permettent pas de faire des calculs précis, car les classes n'ont pas de valeur numérique réelle. Elles servent surtout à comparer et à classer.

Ce principe permet de représenter des hiérarchies spatiales. En effet, lorsqu'on décrit une ville avec les catégories « centre », « première couronne », « deuxième couronne » et « périphérie », on indique une hiérarchie : le centre est au niveau le plus élevé en termes de centralité, puis les couronnes, et enfin la périphérie. On ne mesure pas la distance exacte entre ces zones, mais on comprend leur position relative.

2. Quel ordre est à privilégier dans les classifications ?

Dans une classification, l'ordre à privilégier est celui qui permet de représenter le plus fidèlement possible la progression du phénomène étudié. Il doit suivre une logique facilement compréhensible et cohérente avec la réalité que l'on cherche à décrire. Cela signifie que les catégories doivent être organisées du niveau le plus faible au niveau le plus fort, ou du moins important au plus important, afin de créer une gradation. Cet ordre peut aussi refléter un mouvement spatial, comme le passage du centre vers la périphérie.

L'objectif est de permettre une lecture fluide et intuitive de la classification. Lorsque les classes sont organisées selon un ordre logique, l'utilisateur peut immédiatement comprendre le sens de la hiérarchie et la manière dont les catégories s'enchaînent. Ainsi, le choix de l'ordre n'est jamais au hasard. Il doit correspondre à la nature du phénomène, à sa dynamique et au message que l'on souhaite transmettre. Un ordre cohérent rend l'analyse plus claire et renforce la pertinence de la classification.

3. Quelle est la différence entre une corrélation des rangs et une concordance de classements ?

La corrélation des rangs cherche à savoir si deux classements évoluent dans le même sens, c'est-à-dire si les positions attribuées aux éléments augmentent ou diminuent de manière similaire d'une liste à l'autre.

La concordance de classements, en revanche, s'intéresse à la coïncidence exacte des positions. Elle cherche à savoir si deux classements placent réellement les éléments dans le même ordre, ou s'ils les classent de manière compatible.

4. Quelle est la différence entre les tests de Spearman et de Kendal ?

Le test de Spearman repose sur la comparaison des rangs attribués à chaque valeur dans les deux séries. Il calcule la corrélation à partir des différences entre ces rangs. Spearman mesure essentiellement la force de la tendance simple, si les éléments montent ou descendent dans le même sens dans les deux classements, même de façon approximative, la corrélation de Spearman sera élevée. C'est un test sensible aux variations dans les positions, car un changement de rang peut influencer fortement le résultat.


Le test de Kendall se base sur le nombre de paires d'éléments concordantes et discordantes. Plutôt que de mesurer des différences de rangs, il s'intéresse à la proportion d'accord global entre les deux classements. Ainsi, Kendall est souvent considéré comme plus robuste, notamment lorsque l'échantillon est petit ou lorsque les données sont similaires. Il mesure davantage la cohérence entre les classements que la variation précise des rangs.

5. À quoi servent les coefficients de Goodman-Krusdal et de Yule ?

Le coefficient de Goodman-Kruskal est utilisé pour mesurer la force d'association entre deux variables qualitatives en indiquant dans quelle mesure la connaissance de l'une permet de prédire l'autre. Il exprime donc un gain d'information : si l'on connaît la catégorie d'un individu dans la première variable, le coefficient indique de combien cela réduit l'incertitude concernant sa catégorie dans la seconde. Ce coefficient est utile dans les analyses où l'on cherche à comprendre quelle variable explique l'autre. On l'utilise notamment pour évaluer la pertinence d'un classement ou pour mesurer la dépendance entre deux typologies qualitatives.

Le coefficient de Yule, de son côté, s'applique surtout aux tables de contingence avec des variables qui n'ont que deux catégories. Il sert à mesurer l'association entre ces deux variables en évaluant si elles ont tendance à apparaître ensemble ou séparément plus souvent que ce que l'on attendrait par hasard. Le coefficient de Yule est très pratique pour analyser des relations binaires. Il permet de dire si la relation entre ces deux modalités est positive, négative, ou inexistante, et d'estimer la force de cette relation.

RESULTATS SCRIPTS PYTHON

Visualisation de la loi rang-taille	
SpearmanrResult(correlation	0.09727602179182566, pvalue=0.20561225645362893)

KendalltauResult(correlation	0.06928104575163399, pvalue=0.17856904513455407)
------------------------------	---

SEANCE 07

REPONSES AUX QUESTIONS

1. Quel est l'intérêt de passer des statistiques univariées aux statistiques bivariées ?

Les statistiques univariées se concentrent sur une seule variable à la fois. Elles permettent de décrire cette variable en détail, par exemple en calculant sa moyenne, sa médiane, sa variance ou en observant sa distribution. Cela donne une bonne idée de la structure de la donnée, mais cela ne permet pas de comprendre comment les variables interagissent entre elles.

Passer aux statistiques bivariées consiste à analyser deux variables simultanément pour explorer leurs relations. L'intérêt principal est de détecter des associations, des corrélations ou des dépendances entre variables. Par exemple, on peut voir si la taille est liée au poids, si le revenu influence le niveau de consommation, ou si deux variables qualitatives sont indépendantes ou liées.

2. Quelles différences opérez-vous entre corrélation et correspondances ? Qu'est-ce qu'un rapport de corrélation ?

La corrélation s'applique généralement à des variables quantitatives et mesure la force et le sens de la relation linéaire entre elles. Le résultat est un coefficient de corrélation compris entre -1 et 1, un coefficient proche de 1 indique une forte corrélation positive (les deux variables augmentent ensemble), un coefficient proche de -1 indique une forte corrélation négative (l'une augmente quand l'autre diminue), et un coefficient proche de 0 signifie qu'il n'y a pas de relation linéaire. Alors que les correspondances s'appliquent surtout à des variables qualitatives et permettent de détecter des associations ou des concordances entre catégories. Les correspondances ne mesurent pas la force d'une relation linéaire mais plutôt la proportion d'accord ou la dépendance entre catégories.

Le rapport de corrélation est un concept lié à la corrélation. Il correspond à une mesure numérique de la relation entre deux variables et sert à quantifier la part de variation d'une variable expliquée par l'autre. Dans le cas d'une corrélation linéaire, le carré du coefficient de corrélation représente la proportion de la variance de l'une des variables qui peut être expliquée par la variation de l'autre.

3. Quelles différences faites-vous entre les valeurs marginales et les valeurs conditionnelles ? Pourquoi distinguer les deux ?

Les valeurs marginales correspondent aux totaux d'une ligne ou d'une colonne. Elles indiquent la répartition globale d'une variable indépendamment de l'autre. Les marges donnent donc une vision globale ou globale partielle des variables, sans tenir compte de l'effet de l'autre variable.

Les valeurs conditionnelles, en revanche, représentent la répartition d'une variable par rapport à une autre, c'est-à-dire sous certaines conditions. Elles permettent donc d'analyser la relation entre les variables et de comprendre comment une variable varie en fonction de l'autre.

Il faut distinguer les deux car, les valeurs marginales servent à connaître la répartition globale de chaque variable, ce qui est utile pour avoir un aperçu général. Alors que les valeurs conditionnelles permettent d'identifier les relations ou dépendances entre les variables, en montrant comment la distribution de l'une change selon l'autre.

4. Quelles différences faites-vous entre variance et covariance ?

La variance mesure à quel point une seule variable s'écarte de sa moyenne. Autrement dit, elle quantifie la dispersion des valeurs autour de la moyenne de cette variable. Une variance élevée signifie que les valeurs sont très dispersées, tandis qu'une variance faible indique que les valeurs sont proches de la moyenne.

La covariance, en revanche, mesure comment deux variables varient ensemble. Elle indique si, lorsque la première variable augmente, la seconde a tendance à augmenter ou à diminuer. Une covariance positive signifie que les deux variables varient dans le même sens (les grandes valeurs de l'une correspondent à de grandes valeurs de l'autre), tandis qu'une covariance négative indique qu'elles varient en sens inverse. Une covariance proche de zéro suggère que les variables ne sont pas linéairement liées.

5. Pourquoi mesurer la corrélation ou l'indépendance ?

Il faut mesurer la corrélation ou l'indépendance entre deux variables, car c'est essentiel pour comprendre les relations existant dans les données et pour prendre des décisions éclairées.

La corrélation permet de savoir si deux variables varient ensemble et dans quelle mesure. La mesurer permet d'identifier des relations importantes qui peuvent être exploitées pour expliquer un phénomène ou prédire des valeurs et de sélectionner des variables pertinentes pour des modèles statistiques ou des analyses plus avancées et d'éviter des erreurs d'interprétation.

L'indépendance permet de vérifier si deux variables ne sont pas liées. Cela permet de confirmer que certaines variables n'influencent pas d'autres, ce qui simplifie les modèles et l'analyse, d'éviter d'utiliser des variables inutiles dans une étude ou une prévision et de comprendre la structure réelle des données, en distinguant les relations significatives des relations aléatoires.

6. Quel est le principe de la méthode des moindres carrés ? À quoi sert-elle ?

La méthode des moindres carrés est une technique statistique utilisée pour trouver la meilleure droite ou courbe qui ajuste un nuage de points dans un graphique. Son principe est de minimiser la somme des carrés des écarts entre les valeurs observées et les valeurs prédites par le modèle. Elle sert principalement à estimer les paramètres d'un modèle linéaire, prévoir ou prédire des valeurs pour une variable à partir d'une autre et évaluer la force et la direction d'une relation linéaire entre deux variables.

7. Expliquez en un court paragraphe ce qu'est la théorie de la corrélation (simple) ?

La théorie de la corrélation étudie la relation entre deux variables quantitatives pour savoir si elles varient ensemble et dans quel sens. Elle permet de mesurer la force et la direction de cette relation à l'aide d'un coefficient de corrélation : positif si les variables augmentent ensemble, négatif si l'une augmente quand l'autre diminue, et proche de zéro si elles ne sont pas liées. Cette théorie sert à comprendre, prévoir et modéliser les comportements des variables dans de nombreuses applications, comme la finance, la biologie ou les sciences sociales.

8. En quoi consiste le piège de l'autocorrélation ?

Le piège de l'autocorrélation se produit lorsque les résidus ou erreurs d'un modèle statistique ne sont pas indépendants les uns des autres, mais corrélés dans le temps ou dans l'espace. Autrement dit, les valeurs observées à un moment donné ou à un endroit donné influencent les valeurs suivantes.

Ce problème est important car l'autocorrélation viole les hypothèses des modèles classiques, ce qui peut fausser les résultats, rendre les tests statistiques invalide et donner des prédictions moins fiables.

9. Expliquez en un court paragraphe ce qu'est une régression linéaire ?

La régression linéaire est une méthode statistique qui permet de modéliser la relation entre une variable dépendante et une ou plusieurs variables indépendantes en utilisant une droite. Elle cherche à prévoir ou expliquer les variations de la variable dépendante à partir des valeurs des variables explicatives. La droite de régression est choisie pour minimiser les écarts entre les valeurs observées et les valeurs prédites, ce qui permet de quantifier l'effet de chaque variable et de faire des prédictions fiables

10. Quelle est la différence entre coefficient de corrélation et coefficient de détermination ?

Le coefficient de corrélation indique simplement si deux variables évoluent ensemble et dans quel sens, tandis que le coefficient de détermination montre à quel point cette relation permet d'expliquer la variation d'une variable par rapport à l'autre. Autrement dit, la corrélation décrit la force et la direction du lien, alors que la détermination traduit la part de l'information réellement expliquée par ce lien.

11. Pourquoi faut-il tester les deux droites de régression ?

Dans une analyse de régression bivariée, il est possible de tracer deux droites de régression : l'une pour prédire Y à partir de X, et l'autre pour prédire X à partir de Y. Il est important de tester les deux droites car la relation entre les variables n'est pas toujours parfaitement symétrique. La droite de régression qui minimise les écarts en Y n'est pas la même que celle qui minimise les écarts en X, et chacune communique des informations différentes sur la dépendance entre les variables. Ainsi tester les deux droites permet donc de mieux comprendre la nature de la relation entre les variables, d'évaluer l'influence de chaque variable et de construire des modèles de prédiction plus précis, selon que l'on cherche à estimer X ou Y.

RESULTATS SCRIPTS PYTHON

Graphique de synthèse de la corrélation	
Calcul de la régression linéaire pour la méthode des moindres carrés	LinregressResult(slope=0.2581100564776539, intercept=16783710277.266685, rvalue=0.8356587406999451, pvalue=1.1047471132695332e-36, stderr=0.014655236966153182)
Calcul du coefficient de corrélation simple de Pearson	(0.8356587406999447, 1.1047471132696927e-36)

SEANCE 08

REPONSES AUX QUESTIONS

1. La corrélation entre deux variables qualitatives a-t-elle un sens ? Expliquez votre réponse.

La corrélation est une mesure statistique qui permet d'évaluer l'intensité et la direction de la relation entre deux variables quantitatives. Elle suppose que les données sont numériques et ordonnées, ce qui permet de calculer des coefficients comme celui de Pearson. Dans le cas de variables qualitatives, cette notion n'a pas véritablement de sens, car les modalités ne sont pas des valeurs numériques que l'on peut comparer ou ordonner.

Cela ne signifie pas pour autant qu'il est impossible d'étudier les relations entre variables qualitatives. On utilise alors d'autres outils statistiques qui ne reposent pas sur la corrélation mais sur l'association ou la dépendance. Le test du chi2 d'indépendance permet de vérifier si deux variables qualitatives sont liées ou indépendantes. Des mesures comme le coefficient de contingence ou le V de Cramer permettent de quantifier l'intensité de cette association. Enfin, des méthodes plus exploratoires comme l'analyse factorielle des correspondances offrent une représentation graphique des relations entre modalités.

2. Pourquoi pratiquer le test d'indépendance du 2 ?

Le test d'indépendance du khi deux est une méthode statistique utilisée pour déterminer s'il existe une relation significative entre deux variables qualitatives. Il repose sur la

comparaison entre les fréquences observées dans un tableau de contingence et les fréquences théoriques que l'on obtiendrait si les deux variables étaient totalement indépendantes.

Il faut pratiquer ce test, car il y a un intérêt double. D'une part, il fournit un cadre rigoureux pour vérifier l'existence d'une association entre variables qualitatives, au-delà des impressions ou des observations empiriques. D'autre part, il permet de quantifier la force de cette relation grâce à des mesures complémentaires comme le V de Cramer. En résumé, pratiquer le test d'indépendance du χ^2 revient à s'assurer que les liens observés entre deux variables qualitatives ne sont pas dus au hasard, mais traduisent une véritable dépendance statistique.

3. Expliquez dans un court paragraphe ce qu'est l'analyse de la variance à simple entrée.

L'analyse de la variance à simple entrée, souvent appelée ANOVA à un facteur, est une méthode statistique qui permet de comparer les moyennes de plusieurs groupes afin de déterminer si elles diffèrent significativement les unes des autres. Elle repose sur la décomposition de la variabilité totale observée dans les données en deux composantes : la variabilité entre les groupes et la variabilité à l'intérieur des groupes. Si la variabilité entre les groupes est nettement plus importante que celle observée à l'intérieur des groupes, on conclut que le facteur étudié exerce une influence sur la variable mesurée. Cette technique est particulièrement utile lorsqu'on souhaite tester l'effet d'un seul critère de classification.

4. Qu'est-ce qu'un rapport de corrélation ? Quelles différences avec la correspondance ?

Le rapport de corrélation est une mesure statistique qui permet d'évaluer l'intensité de la relation entre une variable qualitative et une variable quantitative. Il repose sur la comparaison de la variance expliquée par la variable qualitative avec la variance totale de la variable quantitative. Autrement dit, il indique dans quelle mesure les différences observées entre les groupes définis par la variable qualitative contribuent à expliquer la dispersion des valeurs de la variable quantitative. Plus le rapport de corrélation est proche de 1, plus la variable qualitative explique fortement la variabilité de la variable quantitative.

La correspondance, en revanche, renvoie à une méthode d'analyse spécifique aux variables qualitatives. L'analyse de correspondance, ou analyse factorielle des correspondances (AFC), vise à représenter graphiquement les relations entre les modalités de plusieurs variables qualitatives. Elle ne cherche pas à mesurer une intensité de relation comme le rapport de corrélation, mais à mettre en évidence des associations ou des proximités entre catégories.

5. Qu'est-ce qu'une analyse factorielle ?

L'analyse factorielle est une méthode statistique multivariée qui cherche à réduire la complexité d'un ensemble de données en identifiant des dimensions latentes, appelées facteurs,

capables de résumer les relations entre les variables observées. Au lieu d'examiner séparément chaque variable, elle met en évidence des regroupements qui traduisent des structures sous-jacentes. Cette technique est particulièrement utile lorsque l'on dispose d'un grand nombre de variables corrélées, car elle permet de simplifier l'information tout en conservant l'essentiel de la variabilité. En pratique, l'analyse factorielle est largement utilisée dans les sciences sociales, la psychologie ou le marketing pour révéler des tendances cachées et faciliter l'interprétation des données.

6. Expliquez en un court paragraphe ce qu'est l'analyse factorielle des correspondances

L'analyse factorielle des correspondances est une méthode statistique exploratoire utilisée pour étudier les relations entre plusieurs variables qualitatives. Elle repose sur la construction d'un tableau de contingence et permet de représenter graphiquement, dans un espace de faible dimension, les associations entre les différentes modalités. L'objectif est de mettre en évidence des proximités ou des oppositions entre catégories, en simplifiant la complexité des données tout en conservant l'essentiel de l'information. Cette technique est particulièrement employée dans les sciences sociales et le marketing pour interpréter des enquêtes ou des classifications à partir de données catégorielles.


REPONSES AUX QUESTION PYTHONS

Explication résultat du coefficient

Les résultats obtenus montrent qu'il existe une liaison statistiquement significative entre les deux variables étudiées. Le coefficient de contingence de Pearson, égal à 0,28, indique une liaison d'intensité modérée : les variables ne sont pas indépendantes, mais leur relation n'est pas non plus très forte. Cette interprétation est renforcée par la F-statistique extrêmement élevée (14 075,7) et surtout par le p-value quasi nulle ($5,97 \times 10^{-295}$), qui conduit à rejeter sans ambiguïté l'hypothèse d'indépendance. En d'autres termes, les variations observées entre les catégories ne peuvent pas être dues au hasard : il existe bien une structure de dépendance entre les deux variables analysées.

RESULTATS SCRIPT PYTHON

Comparaison homme/femme	Les totaux des marges lignes et colonnes sont identiques.
Résultats du test χ^2	Statistique χ^2 : 4812.419369442916 Degrés de liberté : 8 p-value : 0.0

Résultat du test chi deux	Contribution des cellules au Chi² <table><tr><td>urs exploitants -</td><td>0.044</td><td>0.044</td></tr><tr><td>fs d'entreprise -</td><td>0.11</td><td>0.11</td></tr><tr><td>les supérieures -</td><td>0.088</td><td>0.088</td></tr><tr><td>intermédiaires -</td><td>0.00064</td><td>0.00064</td></tr><tr><td>Employés -</td><td>0.76</td><td>0.76</td></tr><tr><td>Ouvriers -</td><td>1</td><td>1</td></tr><tr><td>amais travaillé -</td><td>0</td><td>0</td></tr><tr><td>Inactifs -</td><td>0.07</td><td>0.07</td></tr><tr><td>Non classés -</td><td>2.8e-05</td><td>2.8e-05</td></tr><tr><td></td><td>Femmes</td><td>Hommes</td></tr></table> Contribution au Chi²	urs exploitants -	0.044	0.044	fs d'entreprise -	0.11	0.11	les supérieures -	0.088	0.088	intermédiaires -	0.00064	0.00064	Employés -	0.76	0.76	Ouvriers -	1	1	amais travaillé -	0	0	Inactifs -	0.07	0.07	Non classés -	2.8e-05	2.8e-05		Femmes	Hommes
urs exploitants -	0.044	0.044																													
fs d'entreprise -	0.11	0.11																													
les supérieures -	0.088	0.088																													
intermédiaires -	0.00064	0.00064																													
Employés -	0.76	0.76																													
Ouvriers -	1	1																													
amais travaillé -	0	0																													
Inactifs -	0.07	0.07																													
Non classés -	2.8e-05	2.8e-05																													
	Femmes	Hommes																													
Tableau des effectifs attendus	<table><tr><td></td><td>Femmes</td><td>Hommes</td></tr><tr><td>0</td><td>190.614908</td><td>176.385092</td></tr><tr><td>1</td><td>1015.920326</td><td>940.079674</td></tr><tr><td>2</td><td>3472.619273</td><td>3213.380727</td></tr><tr><td>3</td><td>3858.523568</td><td>3570.476432</td></tr><tr><td>4</td><td>3940.067276</td><td>3645.932724</td></tr><tr><td>5</td><td>3028.543670</td><td>2802.456330</td></tr><tr><td>6</td><td>172.955761</td><td>160.044239</td></tr><tr><td>7</td><td>12574.870658</td><td>11636.129342</td></tr><tr><td>8</td><td>63.884560</td><td>59.115440</td></tr></table>		Femmes	Hommes	0	190.614908	176.385092	1	1015.920326	940.079674	2	3472.619273	3213.380727	3	3858.523568	3570.476432	4	3940.067276	3645.932724	5	3028.543670	2802.456330	6	172.955761	160.044239	7	12574.870658	11636.129342	8	63.884560	59.115440
	Femmes	Hommes																													
0	190.614908	176.385092																													
1	1015.920326	940.079674																													
2	3472.619273	3213.380727																													
3	3858.523568	3570.476432																													
4	3940.067276	3645.932724																													
5	3028.543670	2802.456330																													
6	172.955761	160.044239																													
7	12574.870658	11636.129342																													
8	63.884560	59.115440																													
Coefficient de contingence (C de Pearson)	intensite de liaison: 0.2847923928835381 F-statistique : 14075.709717089336 p-value : 5.979964038805318e-295																														
BONUS AFC	AFC / CA - Plan factoriel 																														

SEANCE 09

REPONSES AUX QUESTIONS

1. Pourquoi la géographie a-t-elle si souvent recours à la statistique multivariée ?

La géographie utilise très souvent la statistique multivariée parce qu'elle cherche à comprendre des phénomènes complexes qui dépendent de nombreux facteurs en interaction. Les réalités territoriales, qu'il s'agisse de population, d'économie, d'environnement ou de modes de vie, ne peuvent pas être expliquées par une seule variable. Les méthodes multivariées permettent donc d'analyser simultanément plusieurs dimensions, de repérer les relations entre elles et de dégager les facteurs qui structurent réellement l'espace. Elles offrent aussi une capacité de synthèse précieuse : en réduisant un grand nombre d'informations à quelques axes ou profils, elles rendent lisibles des données volumineuses et facilitent l'interprétation. Ces outils servent enfin à classer les territoires, à identifier des groupes homogènes et à construire des typologies utiles pour l'analyse ou l'aménagement. Dans un contexte où les données sont de plus en plus nombreuses et détaillées, la statistique multivariée est devenue indispensable pour comprendre et représenter la complexité géographique.

2. Expliquez ce que vous avez compris des enjeux scientifiques des méthodes descriptives (un paragraphe par méthode)

- **Analyse en composantes principales (ACP)**

L'enjeu scientifique de l'ACP est de réduire la complexité des données multivariées tout en conservant l'essentiel de l'information. Cette méthode permet d'identifier les grands axes qui structurent un ensemble de variables, en révélant les corrélations fortes et les oppositions majeures entre territoires ou individus statistiques. L'ACP met en lumière des structures déjà présentes dans les données, mais souvent invisibles à l'œil nu. Elle permet ainsi de simplifier des phénomènes complexes, de dégager des gradients géographiques (centre/périphérie, urbain/rural, riche/pauvre) et de produire des représentations synthétiques utiles pour l'interprétation scientifique. Son enjeu principal est donc de rendre lisible la complexité sans la déformer.

- **Analyse factorielle des correspondances (AFC)**

L'AFC répond à un enjeu scientifique différent, elle permet d'explorer les relations entre variables qualitatives, souvent issues d'enquêtes, de typologies ou de tableaux de contingence. Son intérêt est de représenter simultanément les modalités des variables et les individus, afin de visualiser les proximités, les oppositions et les associations significatives. L'AFC met en évidence des structures de correspondance entre catégories (par exemple, types de ménages et types de logements), ce qui est essentiel pour comprendre les logiques sociales ou territoriales. L'enjeu scientifique est donc de détecter des relations non triviales dans des données catégorielles et de les représenter dans un espace géométrique interprétable.

- **Classification ascendante hiérarchique (CAH)**

La CAH répond à l'enjeu scientifique de regrouper des individus ou des territoires en ensembles homogènes, en fonction de leurs caractéristiques multivariées. Contrairement aux méthodes factorielles, elle ne cherche pas à réduire la dimension mais à construire des typologies robustes. Elle permet de révéler des familles de territoires, des profils socio-économiques ou des types de paysages, en s'appuyant sur des distances statistiques calculées entre individus. L'enjeu scientifique est double : d'une part, objectiver la construction de catégories, en évitant les typologies arbitraires ; d'autre part, mettre en évidence des structures latentes dans les données. La CAH est donc un outil central pour la classification scientifique des espaces.

3. **Pour chaque méthode, résumez les éléments que vous devez calculer et mesurer. Attention ! Je vous demande une explication textuelle, et non mathématique, mais vous devez respecter les étapes de calcul.**

- **Analyse en composantes principales (ACP)**

Dans une ACP, on commence par préparer les données : on vérifie les valeurs manquantes, on met toutes les variables sur une base comparable (par exemple en les ramenant à une même échelle) pour éviter que certaines dominent les autres uniquement parce qu'elles sont exprimées en grands nombres. Ensuite, on mesure la variabilité de chaque variable : on regarde à quel point les valeurs diffèrent d'un individu à l'autre. Puis on mesure les relations entre les variables, en évaluant si elles évoluent ensemble (corrélation positive), en sens inverse (corrélation négative) ou sans lien net. À partir de ces relations, on construit de nouveaux axes (les composantes principales), qui sont des combinaisons des variables initiales et qui résument le mieux possible l'information contenue dans les données. On mesure alors la part d'information (ou de variabilité) que chaque axe résume, afin de savoir quels axes sont vraiment importants. Enfin, on calcule la position de chaque individu et de chaque variable sur ces axes pour pouvoir les représenter sur des graphiques et interpréter les structures mises en évidence.

- **Analyse factorielle des correspondances (AFC)**

Dans une AFC, on commence par compter les effectifs dans un tableau croisant deux variables qualitatives (par exemple, types de ménages et types de logements). Chaque case du tableau indique combien d'individus relèvent à la fois d'une modalité de la première variable et d'une modalité de la seconde. On transforme ensuite ce tableau d'effectifs en tableau de fréquences, pour savoir quelle part du total représente chaque case. À partir de là, on calcule ce que seraient les fréquences si les deux variables n'avaient aucun lien entre elles : ce sont les fréquences dites "attendues". On mesure ensuite les écarts entre les fréquences observées et les fréquences attendues : ce sont ces écarts qui révèlent les associations fortes entre modalités (par exemple, tel type de ménage est surreprésenté dans tel type de logement). À partir de ces écarts, on construit des axes factoriels qui résument les correspondances les plus marquées. On calcule enfin la position des modalités et des individus sur ces axes, ce qui permet de visualiser leurs proximités et oppositions dans un plan.

- **Classification ascendante hiérarchique (CAH)**

Dans une CAH, la première étape consiste à mesurer la ressemblance ou la distance entre chaque couple d'individus, en tenant compte de toutes les variables disponibles. Plus deux individus se ressemblent, plus la distance entre eux est faible. Cela donne un tableau de distances entre tous les individus. On commence ensuite la classification : on regroupe d'abord les deux individus les plus proches pour former un premier groupe. Puis on recalcule la distance entre ce nouveau groupe et les autres individus ou groupes déjà formés, selon une règle de calcul choisie (par exemple, distance moyenne entre membres des groupes). On répète ce processus : à chaque étape, on fusionne les deux groupes ou individus les plus proches, puis on met à jour les distances entre les nouveaux groupes. Progressivement, on obtient une hiérarchie de regroupements, représentée sous la forme d'un arbre (le dendrogramme). La dernière étape consiste à choisir un niveau de coupure dans cet arbre, ce qui permet de définir un certain nombre de classes finales : on ne le "calcule" pas au sens strict, mais on l'apprécie en observant à quel moment la fusion des groupes devient moins cohérente (sauts de distance importants).

4. Existe-t-il des points communs entre les différentes méthodes factorielles ? ou sont-elles mathématiquement indépendantes ?

Dans une analyse en composantes principales, il s'agit d'abord de préparer les données en les rendant comparables, afin qu'aucune variable ne domine artificiellement les autres. On mesure ensuite la variabilité de chaque variable pour comprendre comment elles se dispersent dans le jeu de données. Puis on évalue les relations entre ces variables, en observant si elles évoluent ensemble ou au contraire s'opposent. À partir de ces relations, on construit de nouveaux axes qui résument l'information essentielle. On mesure alors la quantité d'information que chaque axe parvient à condenser, ce qui permet de déterminer leur importance. Enfin, on calcule la position des individus et des variables sur ces axes, afin de représenter et d'interpréter les grandes structures du jeu de données.

Dans une analyse factorielle des correspondances, on commence par établir un tableau d'effectifs qui croise deux variables qualitatives. On transforme ensuite ces effectifs en fréquences pour connaître la part que représente chaque case dans l'ensemble du tableau. À partir de là, on calcule les fréquences que l'on obtiendrait si les deux variables n'avaient aucun lien entre elles : ce sont les fréquences attendues. On mesure ensuite les écarts entre les fréquences observées et les fréquences attendues, car ce sont ces écarts qui révèlent les associations significatives entre modalités. Ces écarts servent ensuite à construire des axes factoriels qui résument les correspondances les plus marquées. On calcule enfin la position des modalités et des individus sur ces axes pour visualiser leurs proximités et leurs oppositions.

Dans une classification ascendante hiérarchique, la première étape consiste à mesurer la distance entre tous les individus, c'est-à-dire leur degré de ressemblance ou de différence en fonction des variables étudiées. Une fois ces distances établies, on regroupe les deux individus les plus proches pour former un premier groupe. On calcule ensuite la distance entre ce groupe et les autres individus ou groupes déjà constitués, puis on répète l'opération : à chaque étape, on fusionne les éléments les plus proches. Ce processus successif de regroupements permet de construire une hiérarchie représentée sous forme d'un dendrogramme. La dernière étape

consiste à choisir un niveau de coupure dans cette hiérarchie, ce qui permet de définir un nombre final de classes cohérentes.

5. Pour l'ensemble des méthodes, quels sont les tableaux de données existant ? Définissez-les et expliquez quelles méthodes les utilisant ?

Dans l'ensemble des méthodes descriptives, plusieurs types de tableaux de données servent de point de départ à l'analyse, chacun correspondant à une manière particulière d'organiser l'information. Le premier est le **tableau individus-variables**, qui rassemble en lignes les individus étudiés (par exemple des communes, des ménages, des quartiers) et en colonnes les variables quantitatives qui les décrivent. Chaque case contient une valeur mesurée pour un individu donné. Ce tableau est utilisé par les méthodes qui travaillent sur des données numériques continues, en particulier l'analyse en composantes principales (ACP) et, en amont, la classification ascendante hiérarchique (CAH) lorsqu'elle s'appuie sur des distances calculées à partir de variables quantitatives. Ce tableau permet de mesurer la variabilité des individus, les relations entre variables et les distances entre profils.

Un second type de tableau est le **tableau de contingence**, qui croise deux variables qualitatives. Les lignes correspondent aux modalités de la première variable, les colonnes à celles de la seconde, et chaque case indique l'effectif d'individus appartenant simultanément aux deux catégories. Ce tableau est indispensable pour l'analyse factorielle des correspondances (AFC), qui repose précisément sur la comparaison entre les effectifs observés et ceux que l'on obtiendrait si les deux variables étaient indépendantes. Il permet de mettre en évidence des associations, des oppositions ou des proximités entre modalités.

Enfin, on rencontre également le **tableau de distances**, qui ne contient plus des valeurs de variables mais des mesures de ressemblance ou de dissemblance entre chaque paire d'individus. Chaque case indique à quel point deux individus sont proches ou éloignés selon l'ensemble de leurs caractéristiques. Ce tableau est utilisé principalement par la classification ascendante hiérarchique (CAH), qui s'appuie sur ces distances pour regrouper progressivement les individus les plus proches et construire une typologie. Il peut être calculé à partir d'un tableau individus-variables ou fourni directement lorsque les distances sont déjà connues.

6. Quel est le lien entre le choix de la méthode factorielle et le type de variables ? Selon vous, quelle est l'analyse factorielle la plus générale ? Justifier votre réponse.

Le choix d'une méthode factorielle dépend directement du type de variables que l'on souhaite analyser, car chaque méthode est conçue pour traiter une forme particulière d'information. Lorsque les données sont quantitatives continues, comme des revenus, des densités ou des températures, on utilise l'analyse en composantes principales (ACP). Cette méthode repose sur le calcul de corrélations et de variances, ce qui n'a de sens que pour des variables numériques. À l'inverse, lorsque les données sont qualitatives, c'est-à-dire organisées en catégories (types de ménages, catégories socioprofessionnelles, types de logements), on utilise l'analyse factorielle des correspondances (AFC), qui s'appuie sur un tableau de contingence et sur la comparaison entre effectifs observés et attendus. Enfin, lorsque les

données sont mixtes, c'est-à-dire qu'elles combinent à la fois des variables quantitatives et qualitatives, on se tourne vers des méthodes adaptées comme l'analyse des correspondances multiples (ACM) ou l'analyse factorielle mixte (AFM), qui permettent de traiter simultanément les deux types d'information. Ainsi, le type de variables conditionne entièrement la méthode factorielle mobilisée, car chaque méthode repose sur des calculs spécifiques adaptés à la nature des données.

Si l'on cherche à identifier l'analyse factorielle la plus générale, c'est-à-dire celle qui peut s'appliquer au plus grand nombre de situations, l'analyse factorielle mixte (AFM) occupe cette position. Elle est en effet conçue pour traiter simultanément des variables quantitatives et qualitatives, ce qui la rend plus flexible que l'ACP, limitée aux données numériques, ou que l'AFC, limitée aux données catégorielles. L'AFM généralise en quelque sorte les principes de l'ACP et de l'ACM en les intégrant dans un cadre commun, capable de gérer des tableaux de données hétérogènes. C'est cette capacité à intégrer plusieurs types de variables dans une même analyse qui en fait la méthode la plus générale parmi les analyses factorielles descriptives.

7. Quelles différences existe-t-il entre une régression par les moindres carrés et une régression orthogonale ?

La régression par les moindres carrés ordinaires repose sur l'idée que seule la variable expliquée comporte une erreur de mesure. On cherche donc à ajuster une droite qui minimise exclusivement les écarts verticaux entre les points observés et la droite estimée. Autrement dit, on mesure la qualité de l'ajustement en regardant à quel point les valeurs observées de la variable dépendante s'éloignent, vers le haut ou vers le bas, de la valeur prédite. Cette méthode suppose que la variable explicative est parfaitement connue et sans incertitude, ce qui en fait une approche asymétrique : on explique Y à partir de X, mais X est considéré comme exact. C'est la méthode la plus couramment utilisée en statistique classique.

La régression orthogonale, au contraire, part du principe que les deux variables comportent des erreurs de mesure. Elle cherche donc à ajuster une droite qui minimise la distance perpendiculaire entre chaque point et la droite, et non plus seulement la distance verticale. Cette méthode est symétrique : elle ne privilégie ni X ni Y, car elle considère que les deux sont incertains. Elle est particulièrement adaptée lorsque les deux variables sont mesurées avec une précision comparable, ou lorsqu'on cherche à mettre en évidence une relation structurelle plutôt qu'une relation de prédiction. La droite obtenue peut être différente de celle des moindres carrés, car elle tient compte de la dispersion dans les deux directions.

Ainsi, la différence fondamentale entre les deux méthodes réside dans la manière dont elles mesurent les écarts entre les données et la droite d'ajustement : verticalement pour les moindres carrés, en supposant X sans erreur, et perpendiculairement pour la régression orthogonale, en reconnaissant une incertitude dans les deux variables. Cette distinction reflète deux conceptions différentes de la relation entre variables : l'une orientée vers la prédiction, l'autre vers la représentation fidèle d'un lien structurel.

8. En analyse factorielle, que signifient les valeurs propres d'un axe d'un point de vue statistique ?

En analyse factorielle, les valeurs propres associées aux axes représentent la quantité d'information statistique que chaque axe parvient à résumer à partir du tableau de données initial. Plus précisément, une valeur propre mesure la part de la variabilité totale (ou de l'inertie, selon le type de données) captée par l'axe correspondant. Un axe ayant une grande valeur propre est donc un axe qui concentre une portion importante des différences observées entre les individus ou entre les modalités. À l'inverse, une valeur propre faible indique que l'axe n'apporte qu'une information marginale et qu'il ne contribue que très peu à la compréhension de la structure des données.

D'un point de vue statistique, les valeurs propres permettent ainsi de hiérarchiser les axes : elles indiquent lesquels sont les plus pertinents pour résumer les données et lesquels peuvent être négligés sans perte majeure d'information. Elles servent également à évaluer la qualité de la réduction de dimension, en montrant combien d'axes sont nécessaires pour restituer une proportion satisfaisante de la variabilité initiale. En somme, les valeurs propres sont un indicateur central de la capacité d'un axe à représenter fidèlement la structure statistique du jeu de données.

9. Qu'est-ce et à quoi sert la distance du χ^2 ?

La distance du chi deux est une mesure statistique utilisée pour comparer des profils dans un tableau de contingence, c'est-à-dire des distributions exprimées en proportions plutôt qu'en effectifs bruts. Elle permet d'évaluer à quel point deux profils se ressemblent ou se différencient, en tenant compte du poids relatif de chaque modalité. Contrairement à une distance classique, elle accorde davantage d'importance aux colonnes ou aux lignes rares, car ce sont elles qui apportent le plus d'information statistique. Cette distance ne compare donc pas simplement des nombres, mais la manière dont chaque modalité se répartit dans l'ensemble du tableau.

Son utilité apparaît pleinement dans l'analyse factorielle des correspondances. C'est en effet cette distance qui sert de base à la construction de l'espace factoriel, les modalités proches selon la distance du chi deux seront représentées près l'une de l'autre, tandis que celles qui présentent des profils très différents seront éloignées. La distance du chi deux permet ainsi de transformer un tableau d'effectifs en une représentation géométrique cohérente, où les relations entre modalités deviennent visibles. Elle met en évidence les écarts entre ce que l'on observe et ce que l'on attendrait si les variables étaient indépendantes, ce qui en fait un outil essentiel pour comprendre les associations, les oppositions et les proximités dans les données qualitatives.

10. Quelles différences entre analyse factorielle des correspondances et analyse des correspondances multiples, et entre analyse en composantes principales et analyse des correspondances multiples ?

L'analyse factorielle des correspondances et l'analyse des correspondances multiples reposent sur un même principe, mais elles ne s'appliquent pas aux mêmes types de tableaux. L'analyse factorielle des correspondances est conçue pour étudier un tableau de contingence croisant deux variables qualitatives. Elle met en évidence les associations entre les modalités de ces deux variables en comparant les effectifs observés à ceux que l'on obtiendrait si les variables étaient indépendantes. L'analyse des correspondances multiples, en revanche, généralise cette logique à un ensemble de variables qualitatives. Elle s'appuie sur un tableau disjonctif complet, où chaque modalité devient une colonne, et permet d'explorer simultanément plusieurs dimensions catégorielles. Ainsi, l'AFC traite un tableau croisé simple, tandis que l'ACM traite un tableau élargi issu de plusieurs variables qualitatives.

La différence entre l'analyse en composantes principales et l'analyse des correspondances multiples tient principalement au type de données et à la manière dont l'information est mesurée. L'analyse en composantes principales s'applique exclusivement à des variables quantitatives, et elle cherche à résumer la variabilité des données en construisant des axes qui maximisent la variance expliquée. L'analyse des correspondances multiples, elle, s'applique à des variables qualitatives, et elle mesure non pas la variance mais l'inertie, c'est-à-dire la dispersion des profils de modalités dans le tableau disjonctif. L'ACM peut être vue comme l'équivalent de l'ACP pour des données catégorielles : elle réduit la dimension, construit des axes factoriels et projette individus et modalités dans un espace commun, mais elle le fait à partir d'un codage binaire des modalités et non de valeurs numériques continues.

11. À quoi servent les profils lignes et les profils colonnes

Dans une analyse factorielle des correspondances, les profils lignes et les profils colonnes servent à décrire la manière dont les modalités d'une variable se répartissent par rapport aux modalités de l'autre. Un profil ligne correspond à la distribution d'une modalité de la variable en ligne à travers l'ensemble des colonnes : il indique, en proportion, comment cette modalité se répartit entre les différentes catégories de la variable en colonne. De la même manière, un profil colonne décrit la répartition d'une modalité de la variable en colonne à travers les lignes. Ces profils permettent donc de comparer les comportements relatifs des modalités, indépendamment des effectifs bruts, et de repérer les associations ou oppositions entre catégories.

Ces profils jouent un rôle central dans l'AFC, car ce sont eux qui servent de base au calcul des distances entre modalités. En effet, l'analyse ne compare pas les effectifs eux-mêmes, mais les formes des profils : deux modalités sont proches si leurs profils sont similaires, c'est-à-dire si elles se répartissent de manière comparable dans les autres catégories. Les profils lignes et colonnes permettent ainsi de transformer un tableau d'effectifs en un ensemble de distributions comparables, ce qui rend possible la représentation géométrique des modalités dans l'espace factoriel. Ils constituent donc l'outil fondamental pour comprendre les relations entre les deux variables qualitatives étudiées.

12. Quels sont les types de mapping ? Comment les interpréter ?

En analyse factorielle, plusieurs types de représentations graphiques, souvent appelées *mappings*, permettent de visualiser les résultats et d'interpréter les relations entre individus, variables ou modalités. Le premier type est le **mapping des individus**, qui projette chaque individu statistique dans l'espace factoriel. Il sert à repérer des proximités, des oppositions ou des regroupements entre individus ayant des profils similaires. Les individus proches sur le graphique partagent des caractéristiques communes, tandis que ceux situés à l'opposé se distinguent nettement. Ce mapping permet donc d'identifier des structures, des clusters ou des gradients dans la population étudiée.

Un second type est le **mapping des variables** (en ACP) ou des **modalités** (en AFC ou ACM). Dans le cas des variables quantitatives, leur position indique leur contribution aux axes : les variables proches d'un axe sont celles qui expliquent le mieux sa signification. Les angles entre variables renseignent sur leurs relations : un angle aigu traduit une corrélation positive, un angle obtus une corrélation négative, et un angle droit une absence de lien. Dans le cas des modalités qualitatives, les modalités proches partagent des comportements similaires, tandis que les modalités éloignées s'opposent. Ce mapping permet donc d'interpréter le sens des axes et de comprendre quelles dimensions structurent les données.

Enfin, certaines analyses proposent un **mapping mixte**, où individus et variables (ou modalités) sont représentés simultanément. Ce type de graphique permet de relier directement les individus aux variables qui les caractérisent le plus fortement. Un individu situé près d'une variable ou d'une modalité est fortement associé à celle-ci. Ce mapping est particulièrement utile pour interpréter les profils typiques et comprendre comment les dimensions statistiques se traduisent concrètement dans les données.

13. Comment expliqueriez-vous la généralisation de l'A.F.C. en A.C.M.?

L'analyse factorielle des correspondances (AFC) constitue le point de départ de l'analyse des correspondances multiples (ACM), car cette dernière n'est rien d'autre que la généralisation de l'AFC à plus de deux variables qualitatives. L'AFC s'applique uniquement à un tableau de contingence croisant deux variables catégorielles : elle étudie les écarts entre les effectifs observés et ceux que l'on obtiendrait si les deux variables étaient indépendantes. L'ACM reprend exactement ce principe, mais elle l'étend à un ensemble plus large de variables qualitatives, en construisant un tableau disjonctif complet où chaque modalité devient une colonne. Ce tableau élargi permet de traiter simultanément plusieurs dimensions catégorielles, tout en conservant la logique de l'AFC, comparer des profils, mesurer des distances entre modalités et représenter les relations dans un espace factoriel.

Ainsi, l'ACM peut être vue comme une AFC appliquée non plus à un tableau croisé simple, mais à un tableau beaucoup plus riche, construit à partir de plusieurs variables qualitatives. Elle en reprend les fondements, analyse des profils, inertie, distances du chi-deux, mais les applique à une structure de données plus complexe. C'est cette capacité à intégrer plusieurs variables qualitatives dans un cadre unique qui fait de l'ACM la véritable généralisation de l'AFC.

14. Comment distinguer classification et classement ? Expliquez les statistiques de regroupements ? Trouvez les situations d'utilisation de l'une ou de l'autre.

La différence entre classification et classement repose sur la nature même de l'opération statistique. Le classement consiste à ordonner des individus selon une variable ou un critère unique : on établit une hiérarchie, du plus grand au plus petit, du plus rapide au plus lent, du plus riche au plus pauvre. Le classement est donc unidimensionnel et repose sur une seule mesure. La classification, au contraire, vise à regrouper des individus en classes homogènes à partir de plusieurs variables simultanément. Elle ne cherche pas à établir un ordre, mais à identifier des ensembles cohérents d'individus qui se ressemblent entre eux et se distinguent des autres. La classification est donc multidimensionnelle et descriptive, tandis que le classement est hiérarchique et comparatif.

Les statistiques de regroupement interviennent dans la classification. Elles consistent d'abord à mesurer la distance ou la similarité entre individus, en tenant compte de toutes les variables disponibles. Plus deux individus ont des profils proches, plus leur distance est faible. À partir de ces distances, les méthodes de classification, comme la classification ascendante hiérarchique, regroupent progressivement les individus les plus proches, puis les groupes les plus similaires, jusqu'à former une hiérarchie complète de regroupements. Ces statistiques permettent donc de transformer un ensemble complexe de données en une typologie lisible, où chaque classe représente un profil moyen ou un type d'individu.

Les situations d'utilisation du classement et de la classification diffèrent nettement. Le classement est utilisé lorsque l'objectif est de comparer des individus selon un critère unique : classer des villes selon leur population, des élèves selon leur note, des pays selon leur PIB. Il sert à établir une hiérarchie ou à identifier un "meilleur" et un "moins bon". La classification, en revanche, est mobilisée lorsque l'on cherche à comprendre la structure d'un ensemble d'individus en tenant compte de plusieurs dimensions : typologie de communes selon leurs caractéristiques socio-économiques, regroupement de quartiers selon leurs profils démographiques, segmentation de consommateurs selon leurs comportements. Elle sert à révéler des familles, des profils ou des types, et non à établir un ordre.

15. Construisez une explication de l'intérêt de faire une A.F.M. ? Pourquoi existe-t-il autant de modèle en A.F.M. ? Quelle est sa particularité par rapport à l'ensemble des méthodes factorielles précédentes ? Existe-t-il des objets Python permettant de les calculer

L'intérêt principal de l'Analyse Factorielle Mixte réside dans sa capacité à traiter simultanément des variables quantitatives et qualitatives au sein d'un même cadre statistique. Là où les méthodes factorielles classiques imposent de choisir entre des données numériques (ACP) ou catégorielles (AFC, ACM), l'AFM permet d'intégrer les deux types d'information sans les déformer. Elle offre ainsi une vision globale d'un jeu de données hétérogène, en respectant la nature propre de chaque variable. Cette capacité à synthétiser des données mixtes en un espace factoriel unique en fait un outil particulièrement adapté aux enquêtes

socio-économiques, aux études territoriales ou aux analyses multidimensionnelles où les variables ne sont jamais toutes du même type.

S'il existe autant de modèles en AFM, c'est parce que les situations d'analyse sont elles-mêmes très diverses. Certaines AFM privilégient l'équilibre entre groupes de variables, d'autres cherchent à pondérer différemment les variables quantitatives et qualitatives, d'autres encore s'adaptent à des structures hiérarchiques ou à des données organisées en blocs. Chaque variante répond à une problématique spécifique : éviter qu'un groupe de variables domine l'analyse, gérer des variables très nombreuses, intégrer des données structurées ou corriger des déséquilibres entre modalités. Cette diversité reflète la volonté d'adapter la méthode à la complexité des données réelles, qui ne se plient pas toujours au cadre strict d'une analyse factorielle standard.

La particularité de l'AFM, par rapport aux méthodes factorielles précédentes, est précisément d'être une méthode unificatrice. Elle généralise l'ACP, l'AFC et l'ACM en proposant un cadre commun capable de gérer des données mixtes. Là où l'ACP ne traite que des variables numériques et où l'AFC/ACM ne traite que des variables qualitatives, l'AFM combine les deux logiques : elle utilise la variance pour les variables quantitatives et l'inertie du khi-deux pour les variables qualitatives, tout en les ramenant à une échelle comparable. Elle constitue ainsi la méthode factorielle la plus flexible et la plus générale parmi les approches descriptives classiques.



Enfin, il existe effectivement des objets Python permettant de calculer une AFM. Plusieurs bibliothèques proposent des implémentations fiables, notamment `prince`, qui offre des classes dédiées à l'AFM, à l'ACP, à l'AFC et à l'ACM dans un cadre cohérent. D'autres bibliothèques comme `scikit-learn` ne proposent pas directement l'AFM, mais permettent de construire des approches hybrides en combinant prétraitements et modèles adaptés. L'existence de ces outils facilite grandement l'utilisation de l'AFM dans les analyses modernes, en particulier lorsqu'il s'agit de traiter des bases de données complexes et hétérogènes.

16. À quelle branche mathématique appartiennent les méthodes factorielles ?


Les méthodes factorielles appartiennent à la branche des statistiques multivariées, un domaine des mathématiques qui étudie simultanément plusieurs variables afin de comprendre les structures complexes qu'elles forment ensemble. Elles s'inscrivent également dans le cadre plus large de l'analyse linéaire, car elles reposent sur des outils issus de l'algèbre linéaire, comme les décompositions matricielles, les valeurs propres et les vecteurs propres. Leur objectif est de représenter des données multidimensionnelles dans un espace de dimension réduite, tout en conservant l'essentiel de l'information statistique. Ainsi, les méthodes factorielles se situent à la croisée de la statistique, de la géométrie et de l'algèbre linéaire, et constituent l'un des piliers de l'analyse exploratoire des données.

RESULTATS SCRIPT PYTHON


ACP



ACM



Dendrogramme



SEANCE 10

REPONSES AUX QUESTIONS

1. Essayez d'expliquer la généralisation de la corrélation dans un espace à n dimensions ?

La corrélation classique mesure la force et la direction de la relation entre deux variables quantitatives. Lorsqu'on passe à un espace à n dimensions, c'est-à-dire lorsque l'on considère simultanément plusieurs variables, la notion de corrélation se généralise à travers des outils comme la matrice de corrélation et l'analyse en composantes principales (ACP).

La matrice de corrélation regroupe l'ensemble des coefficients de corrélation entre chaque paire de variables. Elle permet de visualiser et de quantifier les interdépendances dans un système multidimensionnel. Mais au-delà de simples relations deux à deux, on cherche souvent à comprendre la structure globale des données. C'est là qu'intervient l'ACP : elle consiste à projeter les données dans un nouvel espace de dimension réduite, construit à partir de combinaisons linéaires des variables initiales, de manière à conserver le maximum de variance. Les axes factoriels obtenus reflètent les directions où la corrélation entre variables est la plus forte.

Ainsi, la généralisation de la corrélation dans un espace à n dimensions ne se limite pas à examiner chaque paire de variables, mais vise à analyser l'ensemble des relations

simultanément. Elle permet de mettre en évidence des structures latentes, des groupes de variables corrélées, et de simplifier la représentation des données tout en gardant l'essentiel de l'information. En résumé, la corrélation généralisée devient une étude globale des dépendances dans un système multidimensionnel, et se traduit par des outils comme la matrice de corrélation et les méthodes factorielles.

2. Comment expliqueriez-vous ce qu'est une régression multiple ?

La régression multiple est une méthode statistique qui permet d'analyser la relation entre une variable dépendante et plusieurs variables explicatives. Contrairement à la régression simple, qui ne prend en compte qu'un seul facteur, la régression multiple cherche à mesurer l'effet simultané de plusieurs variables indépendantes sur la variable étudiée. Elle repose sur un modèle linéaire où la variable dépendante est exprimée comme une combinaison des différentes variables explicatives, pondérées par des coefficients.

Cette technique est particulièrement utile lorsqu'on veut comprendre des phénomènes complexes influencés par plusieurs facteurs à la fois. Par exemple, le revenu d'un individu peut dépendre de son niveau d'éducation, de son expérience professionnelle et de son âge. La régression multiple permet alors de quantifier l'impact de chacun de ces facteurs, tout en tenant compte de la présence des autres.

3. À quoi sert l'analyse de la variance à double entrée ?

L'analyse de la variance à double entrée, aussi appelée ANOVA à deux facteurs, est une méthode statistique qui permet d'étudier simultanément l'effet de deux variables qualitatives sur une variable quantitative. Elle sert à déterminer si chacune des variables indépendantes exerce une influence significative sur la variable dépendante, mais aussi à vérifier s'il existe une interaction entre elles. Autrement dit, elle ne se limite pas à comparer des moyennes selon un seul critère, mais examine la combinaison de deux critères à la fois. Par exemple, on peut analyser l'effet du type de formation et du genre sur les résultats scolaires, l'ANOVA à double entrée permet de savoir si chaque facteur a un impact séparé et si leur interaction produit un effet particulier. Cette approche est donc utile pour comprendre des phénomènes complexes où plusieurs facteurs interviennent simultanément.

4. Pourquoi malgré le fait que l'analyse canonique soit la plus générale, ne sert-elle à rien en analyse de données ?

L'analyse canonique, ou analyse canonique des corrélations, est en effet l'une des méthodes les plus générales de la statistique multivariée. Elle cherche à mettre en relation deux ensembles de variables en construisant des combinaisons linéaires optimales de chaque ensemble, de manière à maximiser la corrélation entre ces combinaisons. En théorie, elle englobe et généralise d'autres méthodes comme la régression multiple, l'analyse discriminante ou même certaines formes d'analyse factorielle. Cependant, dans la pratique de l'analyse de données, elle est rarement utilisée car elle souffre de plusieurs limites. D'abord, son

interprétation est complexe : les combinaisons linéaires obtenues n'ont souvent pas de signification claire, ce qui rend difficile la lecture des résultats. Ensuite, elle est très sensible aux problèmes de multi colinéarité et aux tailles d'échantillons réduites, ce qui peut conduire à des résultats instables. Enfin, d'autres méthodes plus spécifiques et plus faciles à interpréter, comme l'analyse en composantes principales, l'analyse factorielle des correspondances ou la régression multiple, répondent généralement mieux aux besoins concrets des chercheurs et des praticiens.

5. À quoi les méthodes explicatives peuvent-elles être utiles dans des analyses de données géographiques ?

Les méthodes explicatives sont particulièrement utiles dans les analyses de données géographiques car elles permettent de comprendre les mécanismes qui sous-tendent la répartition spatiale des phénomènes. Plutôt que de se limiter à une description ou à une représentation cartographique, elles cherchent à identifier les facteurs qui influencent la localisation et l'intensité des variables étudiées. Par exemple, une régression multiple appliquée à des données géographiques peut montrer comment la densité de population, la proximité des infrastructures ou les caractéristiques socio-économiques expliquent la variation d'un indicateur de santé ou d'un usage du sol. Ces méthodes offrent ainsi la possibilité de passer de la simple observation à l'interprétation, en mettant en évidence des relations de causalité ou de dépendance. Elles sont essentielles pour élaborer des modèles prédictifs, orienter les politiques publiques et mieux comprendre les dynamiques spatiales complexes.

REPONSES AUX QUESTIONS PYTHON

Analyse de mes paramètres

Les deux régressions montrent des modèles globalement performants. Dans le premier, la température de janvier est très bien expliquée par la latitude, la longitude et l'altitude, avec un R^2 de 0,85. Les coefficients sont cohérents : la température baisse quand on monte en latitude ou en altitude, et augmente légèrement avec la longitude. Toutes les variables sont significatives, ce qui confirme la solidité du modèle, même si une certaine multicolinéarité est possible.

Le second modèle, appliqué à la variable `ça`, présente aussi un bon pouvoir explicatif ($R^2 \approx 0,78$). Plusieurs variables sont significatives — surface totale, potentiel Z20, effectifs scolaires, pharmacies, concentrations Z20, ménages — ce qui montre que `ça` dépend de facteurs structurels et démographiques variés. D'autres variables ne sont pas significatives, et le condition number très élevé indique une forte multicolinéarité, ce qui peut rendre certains coefficients instables. Malgré cela, le modèle reste globalement pertinent et statistiquement significatif.

Temperature_en_janvier Latitude Longitude Altitude

Temperature_en_janvier	1.000000	-0.867062	-0.017703	-0.492481
Latitude	-0.867062	1.000000	0.179317	0.352345
Longitude	-0.017703	0.179317	1.000000	0.458797
Altitude	-0.492481	0.352345	0.458797	1.000000

	Temperature_en_janvier	Latitude	Longitude	Altitude
count	4.000000	4.000000	4.000000	4.000000
mean	-0.094312	0.166150	0.405103	0.329665
std	0.808098	0.774096	0.442165	0.617107
min	-0.867062	-0.867062	-0.017703	-0.492481
25%	-0.586126	-0.082278	0.130062	0.141139
50%	-0.255092	0.265831	0.319057	0.405571
75%	0.236722	0.514259	0.594098	0.594098
max	1.000000	1.000000	1.000000	1.000000

OLS Regression Results

```
=====
=====
Dep. Variable:  Temperature_en_janvier  R-squared:          0.854
Model:          OLS  Adj. R-squared:      0.839
Method:         Least Squares  F-statistic:      56.68
Date:           Fri, 19 Dec 2025  Prob (F-statistic):  3.04e-12
Time:           23:40:00  Log-Likelihood:    -83.607
No. Observations:  33  AIC:                175.2
Df Residuals:      29  BIC:                181.2
Df Model:           3
```

Covariance Type: nonrobust

```
=====
=====
              coef  std err          t  P>|t|  [0.025    0.975]
-----
const      29.6809    5.396     5.501  0.000    18.646    40.716
Latitude   -1.1335    0.108   -10.527  0.000    -1.354    -0.913
Longitude    0.1460    0.041     3.529  0.001     0.061     0.231
Altitude   -0.0055    0.001    -4.062  0.000    -0.008    -0.003
=====
=====
```

```
=====
Omnibus:          1.029  Durbin-Watson:          1.713
Prob(Omnibus):    0.598  Jarque-Bera (JB):          0.256
Skew:             0.093  Prob(JB):              0.880
Kurtosis:         3.389  Cond. No.              5.71e+03
```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 5.71e+03. This might indicate that there are strong multicollinearity or other numerical problems.

Coefficients :

const 29.680897

Latitude -1.133538

Longitude 0.145987

Altitude -0.005514

dtype: float64

R² : 0.8542941238217661

P-values :

const 6.309568e-06

Latitude 2.030559e-11

Longitude 1.411399e-03

Altitude 3.383523e-04

dtype: float64

Coefficients : [0. -1.13353791 0.14598702 -0.00551395]

Intercept : 29.680897329185125

OLS Regression Results

Dep. Variable: ca R-squared (uncentered):

0.784

Model: OLS Adj. R-squared (uncentered):

0.777

Method: Least Squares F-statistic:

123.1

Date: Fri, 19 Dec 2025 Prob (F-statistic): 1.41e-106

Time: 23:40:00 Log-Likelihood: -5202.2

No. Observations: 350 AIC: 1.042e+04

Df Residuals: 340 BIC: 1.046e+04

Df Model: 10

Covariance Type: nonrobust

	coef	std err	t	P> t	[0.025	0.975]
surface_totale	672.5588	282.198	2.383	0.018	117.484	1227.633
potentiel_Z20	0.0994	0.025	3.963	0.000	0.050	0.149
nb_primaire_Z10	1.756e+04	5361.545	3.276	0.001	7018.697	2.81e+04
nb_primaire_Z20	8120.6473	3982.659	2.039	0.042	286.893	1.6e+04
nb_gsa_Z10	1320.6327	1298.476	1.017	0.310	-1233.425	3874.690
nb_pharmacie_Z5	2592.0487	1163.819	2.227	0.027	302.856	4881.242
nb_conc2_Z10	7.01e+04	4.45e+04	1.574	0.116	-1.75e+04	1.58e+05
nb_conc2_Z20	9.723e+04	4.6e+04	2.113	0.035	6713.214	1.88e+05
P10_POP_Z15	0.0238	0.259	0.092	0.927	-0.487	0.534
P10_MEN_Z10	1.6092	0.613	2.624	0.009	0.403	2.815
Omnibus: 42.088 Durbin-Watson: 1.924						
Prob(Omnibus): 0.000 Jarque-Bera (JB): 13.042						
Skew: 0.152 Prob(JB): 0.00147						
Kurtosis: 2.104 Cond. No. 3.60e+06						

Notes:

[1] R^2 is computed without centering (uncentered) since the model does not contain a constant.

[2] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[3] The condition number is large, 3.6e+06. This might indicate that there are strong multicollinearity or other numerical problems.

Coefficients :

```
surface_totale    672.558814
potentiel_Z20     0.099383
nb_primaire_Z10   17564.672327
nb_primaire_Z20   8120.647284
nb_gsa_Z10        1320.632677
nb_pharmacie_Z5   2592.048730
nb_conc2_Z10      70095.220817
nb_conc2_Z20      97232.608746
P10_POP_Z15       0.023822
P10_MEN_Z10       1.609165
dtype: float64
```

R^2 : 0.783575392281959

P-values :

```
surface_totale    0.017708
potentiel_Z20     0.000090
nb_primaire_Z10   0.001161
nb_primaire_Z20   0.042223
nb_gsa_Z10        0.309846
nb_pharmacie_Z5   0.026589
nb_conc2_Z10      0.116367
nb_conc2_Z20      0.035343
P10_POP_Z15       0.926903
P10_MEN_Z10       0.009078
dtype: float64
```

REFLEXION PERSONNELLE SUR LES SCIENCES DES DONNEES ET LES HUMANITES NUMERIQUE

Les exercices que j'ai traversés autour des méthodes factorielles, des classifications et des distances statistiques montrent à quel point les sciences des données et les humanités numériques reposent sur une même ambition : rendre intelligible la complexité. Derrière chaque tableau, chaque distance du χ^2 , chaque axe factoriel, il y a une volonté de transformer des données brutes en structures lisibles, en relations visibles, en récits possibles. Les sciences des données ne se limitent pas à manipuler des chiffres ; elles construisent des espaces où les phénomènes prennent forme, où les individus se rapprochent ou s'opposent, où les variables dessinent des dimensions latentes. Les humanités numériques, elles, s'emparent de ces outils pour éclairer des réalités sociales, culturelles ou territoriales qui ne se laissent jamais réduire à une seule dimension.

Travailler avec l'ACP, l'AFC, l'ACM ou l'AFM montre que chaque méthode est une manière différente de regarder le monde. L'ACP révèle les gradients continus, l'AFC met en lumière les associations entre catégories, l'ACM explore la diversité des profils, et l'AFM, plus générale, accepte la complexité des données mixtes. Cette diversité méthodologique n'est pas un luxe : elle reflète la diversité des phénomènes humains. Les humanités numériques ne cherchent pas à imposer un modèle unique, mais à choisir la méthode la plus juste pour la nature des données et la question posée. C'est précisément pour cela qu'il existe autant de variantes en AFM : chaque jeu de données, chaque enquête, chaque corpus appelle un traitement spécifique.

L'usage de Python dans ce parcours renforce cette idée. Les bibliothèques comme *prince* ou *scikit-learn* ne sont pas seulement des outils techniques ; elles incarnent une manière de penser les données comme des objets manipulables, explorables, visualisables. Elles permettent de passer du concept à la pratique, de la théorie statistique à l'expérimentation. Programmer une ACP ou une CAH, ce n'est pas seulement exécuter un algorithme : c'est comprendre comment les distances se construisent, comment les axes émergent, comment les classes se forment. C'est entrer dans la mécanique même de l'analyse, et donc dans la logique profonde des sciences des données.

Au fond, ce parcours montre que les sciences des données et les humanités numériques ne sont pas deux mondes séparés. Les premières apportent les outils, les secondes donnent le sens. Les méthodes factorielles, les distances, les classifications ne prennent toute leur valeur que lorsqu'elles éclairent des réalités humaines : des comportements, des territoires, des pratiques, des cultures. Et inversement, les humanités numériques trouvent dans les sciences des données une rigueur, une précision et une capacité de synthèse qui permettent de dépasser l'intuition pour atteindre une compréhension structurée.

Ainsi, les exercices réalisés ne sont pas seulement des démonstrations techniques ; ils sont une manière d'apprendre à regarder les données comme des traces du réel, à les organiser pour mieux les comprendre, et à mobiliser les outils numériques pour donner forme à des questions profondément humaines. C'est dans cette articulation entre technique et sens, entre calcul et interprétation, que se situe la véritable richesse du dialogue entre sciences des données et humanités numériques.