

Réponses aux questions de la séance 5

1. Comment définir l'échantillonnage. Pourquoi ne pas utiliser la population en entier ? Quelles sont les méthodes d'échantillonnage ? Comment les choisir ?

L'échantillonnage est une méthode qui consiste à sélectionner une partie d'une population afin d'en tirer des conclusions générales. On étudie un groupe réduit d'individus de la population mère, pour comprendre ou estimer les caractéristiques de l'ensemble de la population. Cela permet d'éviter à avoir d'étudier l'ensemble de la population. L'objectif est que cet échantillon soit représentatif, c'est-à-dire qu'il reflète fidèlement la diversité, les proportions et la structure de la population globale.

On n'utilise pas la population entière pour plusieurs raisons. D'abord pour une raison de coût, recueillir des données sur chaque individu d'une population peut être extrêmement cher, surtout si celle-ci est très grande. Ensuite pour une raison de temps, analyser des millions de cas prendrait beaucoup trop longtemps, alors qu'un échantillon permet d'obtenir des résultats rapides et fiables. Enfin, il y a aussi des questions de faisabilité. En effet, certaines populations sont difficiles à atteindre ou à recenser entièrement.

Il existe plusieurs méthodes d'échantillonnage, les méthodes aléatoires et les méthodes non aléatoires.

Les méthodes aléatoires reposent sur le hasard. Chacun a la même probabilité d'être sélectionné :

- l'échantillonnage aléatoire simple, où l'on prend des individus au hasard dans la population,
- l'échantillonnage stratifié, où la population est divisée en groupes homogènes avant de tirer au hasard dans chaque groupe,
- l'échantillonnage par grappes, où ce sont des groupes entiers spécifiques (écoles, quartiers, foyers, ...) qui sont tirés au hasard.

Les méthodes non aléatoires reposent sur un choix raisonné ou pratique.

Le choix de la méthode d'échantillonnage dépend de plusieurs facteurs. Il faut d'abord considérer l'objectif de l'étude : une enquête scientifique exige souvent un échantillonnage aléatoire, tandis qu'une étude rapide correspond mieux à une méthode non aléatoire. Le budget, le temps disponible, la taille de la population et l'accessibilité des individus jouent aussi un rôle important.

2. Comment définir un estimateur et une estimation ?

Un estimateur est un moyen statistique qui permet d'estimer une caractéristique inconnue d'une population, comme sa moyenne, sa proportion ou sa variance. Il s'agit donc d'un outil théorique qui indique comment calculer cette information à partir d'un échantillon.

L'estimation, quant à elle, est la valeur numérique obtenue lorsque l'on applique cet estimateur à un échantillon précis. L'estimation est donc le résultat concret donné par l'estimateur.

3. Comment distingueriez-vous l'intervalle de fluctuation et l'intervalle de confiance ?

L'intervalle de fluctuation permet d'évaluer la variabilité d'une statistique d'échantillon autour de sa valeur attendue lorsque l'on répète l'expérience ou le prélèvement d'échantillons. Si l'on prélève plusieurs échantillons d'une même taille dans une population donnée, la proportion observée dans chaque échantillon peut varier. L'intervalle de fluctuation indique donc la plage de valeurs dans laquelle cette proportion devrait se situer dans la majorité des échantillons, avec un niveau de confiance de 95 %. Il sert principalement à contrôler si un résultat observé est cohérent avec une hypothèse connue sur la population.

L'intervalle de confiance est utilisé pour estimer une caractéristique inconnue de la population, comme une moyenne ou une proportion, à partir d'un seul échantillon. Il fournit une plage de valeurs pour le paramètre inconnu avec un certain niveau de confiance. L'intervalle de confiance contient le paramètre réel de la population avec une probabilité donnée, et il est construit à partir des données observées dans un échantillon unique.

4. Qu'est-ce qu'un biais dans la théorie de l'estimation ?

Dans la théorie de l'estimation, un biais désigne la différence entre la valeur moyenne d'un estimateur et la vraie valeur du paramètre de la population qu'il cherche à estimer. Autrement dit, un estimateur est dit biaisé si, en moyenne, il surestime ou sous-estime systématiquement le paramètre réel. À l'inverse, un estimateur est non biaisé si sa valeur moyenne, lorsqu'on répète l'expérience ou le prélèvement de nombreux échantillons, coïncide exactement avec le paramètre réel.

5. Comment appelle-t-on une statistique travaillant sur la population totale ? Faites le lien avec la notion de données massives 1 ?

Une statistique qui travaille sur la population totale s'appelle une statistique descriptive de population. Ces statistiques sont calculées sur l'ensemble des individus de la population. Elles donnent donc la valeur exacte du paramètre étudié, sans incertitude liée à l'échantillonnage.

Le lien avec les données massives est direct. Les technologies de collecte et de traitement de grandes quantités de données permettent aujourd'hui de travailler sur des populations très vastes, voire sur la quasi-totalité de la population concernée, plutôt que sur un simple échantillon. Dans ce contexte, certaines statistiques calculées sur les données massives peuvent être considérées comme des paramètres exacts, car elles utilisent l'ensemble des données disponibles. Cela réduit l'incertitude et les erreurs liées à l'échantillonnage et permet des analyses plus précises et détaillées.

6. Quels sont les enjeux autour du choix d'un estimateur ?

Le choix d'un estimateur est crucial en statistique, car il détermine la fiabilité et la précision des conclusions que l'on pourra tirer à partir des données. Il y a donc plusieurs enjeux.

Le premier enjeu est celui du biais. Un bon estimateur doit être non biaisé, c'est-à-dire qu'en moyenne, il doit fournir la valeur réelle du paramètre de la population. Si l'estimateur est biaisé, il risque de surestimer ou sous-estimer systématiquement le paramètre, ce qui peut conduire à des conclusions erronées.

Le second enjeu est celui de la variance ou de la dispersion de l'estimateur. Un estimateur non biaisé peut donner des résultats très différents selon l'échantillon choisi. Un bon estimateur doit donc être stable et peu variable, afin que les résultats restent proches de la valeur réelle quelles que soient les observations tirées.

Le troisième enjeu concerne la consistance de l'estimateur. Lorsqu'on augmente la taille de l'échantillon, un estimateur consistant doit se rapprocher de la vraie valeur du paramètre. Cela garantit que les conclusions deviennent plus fiables lorsque l'on dispose de davantage de données.

7. Quelles sont les méthodes d'estimation d'un paramètre ? Comment en sélectionner une ?

En statistique, estimer un paramètre de population consiste à utiliser un estimateur pour obtenir une valeur approximative de ce paramètre à partir d'un échantillon. Il existe plusieurs méthodes d'estimation, chacune ayant ses avantages et ses limites.

La première méthode est l'estimation par la méthode des moments. Elle consiste à égaliser les moments théoriques du paramètre (comme la moyenne ou la variance) aux moments observés dans l'échantillon.

La deuxième méthode est l'estimation par la méthode du maximum de vraisemblance. Cette approche cherche le paramètre qui rend les données observées les plus probables. Elle produit souvent des estimateurs efficaces et consiste à exploiter pleinement l'information contenue dans l'échantillon.

Une troisième approche est l'estimation bayésienne, qui combine les données observées avec des informations sur le paramètre. Cette méthode permet de mettre à jour les connaissances sur le paramètre en intégrant les observations et les hypothèses initiales, ce qui est utile lorsque l'on dispose de données limitées ou que l'on souhaite incorporer des connaissances antérieures.

Le choix de la méthode d'estimation dépend de plusieurs critères. Il faut prendre en compte la nature des données et la distribution du paramètre, la simplicité de calcul, la qualité souhaitée de l'estimation (biais, variance, consistance), ainsi que la disponibilité d'informations supplémentaires.

8. Quels sont les tests statistiques existants ? À quoi servent-ils ? Comment créer un test ?

Il existe une grande variété de tests statistiques, chacun adapté à une situation particulière et au type de données étudiées. Parmi les plus connus, on retrouve les tests sur les moyennes, comme le test t de Student qui compare la moyenne d'un échantillon à une valeur théorique ou à celle d'un autre échantillon. D'autres tests portent sur les proportions, tels que le test du χ^2 d'indépendance qui examine la relation entre deux variables catégorielles, ou le test de proportion qui confronte une proportion observée à une proportion théorique. Les tests de corrélation et d'association, comme le coefficient de Spearman, de Kendall ou le test de Pearson, servent à mesurer la force et la nature des relations entre variables. Enfin, il existe des tests non paramétriques, tels que le test de Wilcoxon, le test de Mann-Whitney ou le test du signe, qui ne supposent pas que les données suivent une loi normale, ainsi que des tests d'ajustement, comme le χ^2 d'ajustement, qui vérifient si une distribution observée correspond à une loi théorique.

Les tests statistiques ont pour finalité de fournir une base objective à la prise de décision. Ils permettent de vérifier des hypothèses concernant des paramètres de population, de détecter des différences entre groupes ou conditions expérimentales, d'évaluer l'indépendance ou la relation entre variables, et de confirmer ou d'infirmer des modèles théoriques. En d'autres termes, ils servent à distinguer les variations dues au hasard de celles qui traduisent des effets réels, garantissant ainsi que les conclusions tirées reposent sur des données fiables plutôt que sur une simple intuition.

La construction d'un test statistique suit une démarche méthodique. Elle commence par la formulation des hypothèses : l'hypothèse nulle, qui représente l'absence d'effet ou de différence, et l'hypothèse alternative, qui traduit l'effet ou la différence recherchée. Ensuite, il faut choisir le test approprié en fonction du type de données, de leur distribution et du nombre d'échantillons. Le chercheur définit ensuite le niveau de signification, souvent fixé à 5 %, qui correspond au risque accepté de rejeter

l'hypothèse nulle alors qu'elle est vraie. Vient ensuite le calcul de la statistique de test, obtenu grâce à la formule spécifique au test choisi, puis la comparaison de cette statistique à une distribution théorique. Enfin, la décision est prise : si la statistique observée est trop improbable sous l'hypothèse nulle, celle-ci est rejetée, sinon elle est conservée.

9. Que pensez-vous des critiques de la statistique inférentielle ?

Les critiques de la statistique inférentielle sont justifiées dans certains cas, mais elles ne remettent pas en cause sa valeur fondamentale. Il est vrai que l'inférence repose sur des échantillons et des hypothèses, ce qui introduit un risque d'erreur et une incertitude. Mais c'est exactement pour cela que les méthodes statistiques incluent des outils pour quantifier cette incertitude, comme les intervalles de confiance et les tests de significativité. Ces outils permettent de prendre des décisions en connaissant le niveau de risque, ce qui est beaucoup plus fiable que de se baser uniquement sur l'intuition. De même, la critique sur les échantillons biaisés est pertinente : un mauvais échantillon peut fausser les résultats. Mais ce problème n'est pas une faiblesse de la statistique inférentielle elle-même, c'est plutôt un enjeu de conception de l'étude. Avec un échantillonnage bien réfléchi et des méthodes adaptées, ce risque peut être fortement réduit. Quant à la dépendance aux modèles et aux hypothèses, cela reflète la puissance de la statistique inférentielle : pour tirer des conclusions sur des populations à partir d'échantillons, il faut poser des hypothèses. L'important est de vérifier leur validité et, si nécessaire, d'utiliser des méthodes non paramétriques ou robustes. Enfin, la mauvaise interprétation des résultats est un problème surtout lié à l'utilisation et la compréhension des outils, pas à leur conception. Avec une formation adéquate et une communication claire, ce problème peut être largement évité.