

Réponses aux questions de la séance 7

1. Quel est l'intérêt de passer des statistiques univariées aux statistiques bivariées ?

Les statistiques univariées se concentrent sur une seule variable à la fois. Elles permettent de décrire cette variable en détail, par exemple en calculant sa moyenne, sa médiane, sa variance ou en observant sa distribution. Cela donne une bonne idée de la structure de la donnée, mais cela ne permet pas de comprendre comment les variables interagissent entre elles.

Passer aux statistiques bivariées consiste à analyser deux variables simultanément pour explorer leurs relations. L'intérêt principal est de détecter des associations, des corrélations ou des dépendances entre variables. Par exemple, on peut voir si la taille est liée au poids, si le revenu influence le niveau de consommation, ou si deux variables qualitatives sont indépendantes ou liées.

2. Quelles différences opérez-vous entre corrélation et correspondances ? Qu'est-ce qu'un rapport de corrélation ?

La corrélation s'applique généralement à des variables quantitatives et mesure la force et le sens de la relation linéaire entre elles. Le résultat est un coefficient de corrélation compris entre -1 et 1, un coefficient proche de 1 indique une forte corrélation positive (les deux variables augmentent ensemble), un coefficient proche de -1 indique une forte corrélation négative (l'une augmente quand l'autre diminue), et un coefficient proche de 0 signifie qu'il n'y a pas de relation linéaire. Alors que les correspondances s'appliquent surtout à des variables qualitatives et permettent de détecter des associations ou des concordances entre catégories. Les correspondances ne mesurent pas la force d'une relation linéaire mais plutôt la proportion d'accord ou la dépendance entre catégories.

Le rapport de corrélation est un concept lié à la corrélation. Il correspond à une mesure numérique de la relation entre deux variables et sert à quantifier la part de variation d'une variable expliquée par l'autre. Dans le cas d'une corrélation linéaire, le carré du coefficient de corrélation représente la proportion de la variance de l'une des variables qui peut être expliquée par la variation de l'autre.

3. Quelles différences faites-vous entre les valeurs marginales et les valeurs conditionnelles ? Pourquoi distinguer les deux ?

Les valeurs marginales correspondent aux totaux d'une ligne ou d'une colonne. Elles indiquent la répartition globale d'une variable indépendamment de l'autre. Les marges donnent donc une vision globale ou globale partielle des variables, sans tenir compte de l'effet de l'autre variable.

Les valeurs conditionnelles, en revanche, représentent la répartition d'une variable par rapport à une autre, c'est-à-dire sous certaines conditions. Elles permettent donc d'analyser la relation entre les variables et de comprendre comment une variable varie en fonction de l'autre.

Il faut distinguer les deux car, les valeurs marginales servent à connaître la répartition globale de chaque variable, ce qui est utile pour avoir un aperçu général. Alors que les valeurs conditionnelles permettent d'identifier les relations ou dépendances entre les variables, en montrant comment la distribution de l'une change selon l'autre.

4. Quelles différences faites-vous entre variance et covariance ?

La variance mesure à quel point une seule variable s'écarte de sa moyenne. Autrement dit, elle quantifie la dispersion des valeurs autour de la moyenne de cette variable. Une variance élevée signifie que les valeurs sont très dispersées, tandis qu'une variance faible indique que les valeurs sont proches de la moyenne.

La covariance, en revanche, mesure comment deux variables varient ensemble. Elle indique si, lorsque la première variable augmente, la seconde a tendance à augmenter ou à diminuer. Une covariance positive signifie que les deux variables varient dans le même sens (les grandes valeurs de l'une correspondent à de grandes valeurs de l'autre), tandis qu'une covariance négative indique qu'elles varient en sens inverse. Une covariance proche de zéro suggère que les variables ne sont pas linéairement liées.

5. Pourquoi mesurer la corrélation ou l'indépendance ?

Mesurer la corrélation ou l'indépendance entre deux variables est essentiel pour comprendre les relations existant dans les données et pour prendre des décisions éclairées.

La corrélation permet de savoir si deux variables varient ensemble et dans quelle mesure. La mesure permet d'identifier des relations importantes qui peuvent être exploitées pour expliquer un phénomène ou prédire des valeurs. De sélectionner des variables pertinentes pour des modèles statistiques ou des analyses plus avancées et d'éviter des erreurs d'interprétation, par exemple en distinguant des relations vraies de coïncidences apparentes.

L'indépendance permet de vérifier si deux variables ne sont pas liées. Cela permet de confirmer que certaines variables n'influencent pas d'autres, ce qui simplifie les modèles et l'analyse, d'éviter d'utiliser des variables inutiles dans une étude ou une prévision et de comprendre la structure réelle des données, en distinguant les relations significatives des relations aléatoires.

6. Quel est le principe de la méthode des moindres carrés ? À quoi sert-elle ?

La méthode des moindres carrés est une technique statistique utilisée pour trouver la meilleure droite ou courbe qui ajuste un nuage de points dans un graphique. Son principe est de minimiser la somme des carrés des écarts entre les valeurs observées et les valeurs prédites par le modèle. Autrement dit, elle cherche à ce que la distance verticale entre chaque point et la droite soit le plus petit possible en moyenne.

Elle sert principalement à estimer les paramètres d'un modèle linéaire, prévoir ou prédire des valeurs pour une variable à partir d'une autre et évaluer la force et la direction d'une relation linéaire entre deux variables.

7. Expliquez en un court paragraphe ce qu'est la théorie de la corrélation (simple) ?

La théorie de la corrélation étudie la relation entre deux variables quantitatives pour savoir si elles varient ensemble et dans quel sens. Elle permet de mesurer la force et la direction de cette relation à l'aide d'un coefficient de corrélation : positif si les variables augmentent ensemble, négatif si l'une augmente quand l'autre diminue, et proche de zéro si elles ne sont pas liées. Cette théorie sert à comprendre, prévoir et modéliser les comportements des variables dans de nombreuses applications, comme la finance, la biologie ou les sciences sociales.

8. En quoi consiste le piège de l'autocorrélation ?

Le piège de l'autocorrélation se produit lorsque les résidus ou erreurs d'un modèle statistique ne sont pas indépendants les uns des autres, mais corrélés dans le temps ou dans l'espace. Autrement dit, les valeurs observées à un moment donné ou à un endroit donné influencent les valeurs suivantes.

Ce problème est important car l'autocorrélation viole les hypothèses des modèles classiques, ce qui peut fausser les résultats, rendre les tests statistiques invalide et donner des prédictions moins fiables.

9. Expliquez en un court paragraphe ce qu'est une régression linéaire ?

La régression linéaire est une méthode statistique qui permet de modéliser la relation entre une variable dépendante et une ou plusieurs variables indépendantes en utilisant une droite. Elle cherche à prévoir ou expliquer les variations de la variable dépendante à partir des valeurs des variables explicatives. La droite de régression est choisie pour minimiser les écarts entre les valeurs observées et les valeurs prédites, ce qui permet de quantifier l'effet de chaque variable et de faire des prédictions fiables.

10. Quelle est la différence entre coefficient de corrélation et coefficient de détermination ?

Le coefficient de corrélation indique simplement si deux variables évoluent ensemble et dans quel sens, tandis que le coefficient de détermination montre à quel point cette relation permet d'expliquer la variation d'une variable par rapport à l'autre. Autrement dit, la corrélation décrit la force et la direction du lien, alors que la détermination traduit la part de l'information réellement expliquée par ce lien.

11. Pourquoi faut-il tester les deux droites de régression ?

Dans une analyse de régression bivariée, il est possible de tracer deux droites de régression : l'une pour prédire Y à partir de X, et l'autre pour prédire X à partir de Y. Il est important de tester les deux droites car la relation entre les variables n'est pas toujours parfaitement symétrique. La droite de régression qui minimise les écarts en Y n'est pas la même que celle qui minimise les écarts en X, et chacune communique des informations différentes sur la dépendance entre les variables. Ainsi tester les deux droites permet donc de mieux comprendre la nature de la relation entre les variables, d'évaluer l'influence de chaque variable et de construire des modèles de prédiction plus précis, selon que l'on cherche à estimer X ou Y.